

Diagnóstico de Falhas Baseado em Dados no Processo Tennessee Eastman: Comparação entre PCA e Autoencoder Undercomplete

José Tayrone Santos de Oliveira

Resumo—Este trabalho apresenta uma implementação de métodos voltados a diagnóstico de falhas baseado em dados aplicada ao benchmark Tennessee Eastman Process. A proposta é comparar duas abordagens encontradas na literatura: a Análise de Componentes Principais, conforme a formulação discutida por Yin et al., e um Autoencoder subcompleto, baseado na estratégia de reconstrução de dados normais discutida por Spina et al. Os modelos foram treinados apenas com dados de operação normal e avaliados nas falhas IDV(1), IDV(3) e IDV(5) do benchmark. O subconjunto de variáveis utilizado foi composto por (XMEAS(1-22) e (XMV(1-11), totalizando 33 variáveis, de modo a manter o PCA alinhado à configuração de Yin et al. e garantir dados comuns para os dois métodos. Os resultados mostram concordância com a literatura para os resultados do PCA e comportamento coerente para o Autoencoder subcompleto. A falha IDV(1) foi facilmente detectada por ambos os modelos, a falha IDV(3) permaneceu difícil e a falha IDV(5) apresentou dificuldade intermediária.

Index Terms—Diagnóstico de falhas, Tennessee Eastman Process, PCA, SPE, T^2 , Autoencoder, aprendizado de máquina.

I. INTRODUÇÃO

Processos industriais modernos são caracterizados por grande número de variáveis medidas e condições operacionais sujeitas a perturbações. Nesse contexto, o monitoramento de tais processos e o diagnóstico de falhas são tarefas importantes quando o intuito é identificar anormalidades na operação e auxiliar na tomada de ações corretivas antes que falhas se propaguem ou afetem pontos como segurança, produtividade e qualidade.

Métodos estatísticos clássicos, como a Análise de Componentes Principais (PCA), são amplamente utilizados devido à simplicidade, interpretabilidade e baixo custo computacional. Porém, técnicas de aprendizado de máquina, como Autoencoders, podem aprender relações não lineares e representar padrões complexos presentes nos dados.

Este estudo propõe três etapas: estudar o Tennessee Eastman Process, preparar o banco de dados e implementar técnicas descritas em dois artigos de referência. O primeiro artigo, de Yin et al. [3], compara métodos básicos de diagnóstico de falhas orientados por dados no benchmark TEP. O segundo artigo, de Spina et al. [4], compara diferentes arquiteturas de Autoencoders para detecção de falhas em processos industriais.

Neste trabalho, optou-se por uma metodologia direta. Do artigo de Yin et al., foi implementado o PCA completo com as estatísticas SPE e T^2 . Do artigo de Spina et al., foi implementado um Autoencoder simples subcompleto. O objetivo não é reproduzir todos os métodos dos dois artigos, mas comparar uma técnica estatística clássica e uma técnica neural simples dentro de um mesmo experimento.

II. BANCO DE DADOS

A. Tennessee Eastman Process

O Tennessee Eastman Process é um benchmark clássico de processo químico utilizado em estudos de controle, simulação e diagnóstico de falhas. O processo representa uma planta química com unidades como reator, condensador, compressor e outros. O sistema possui múltiplas variáveis de processo, variáveis manipuladas e variáveis de composição, além de falhas simuladas de diferentes tipos, como degraus, variações aleatórias e travamento de válvulas [1]–[3].

No conjunto de dados completo, cada amostra é composta por 52 variáveis:

$$\mathbf{x} = [\text{XMEAS}(1), \dots, \text{XMEAS}(41), \text{XMV}(1), \dots, \text{XMV}(11)]^T. \quad (1)$$

As variáveis *XMEAS* representam medições do processo, enquanto as variáveis *XMV* representam variáveis manipuladas pelo sistema de controle. As variáveis *XMEAS*(1 – 22) correspondem principalmente a medições de vazões, pressões, níveis e temperaturas. As variáveis *XMEAS*(23 – 41) correspondem a análises de composição química. As variáveis *XMV*(1 – 11) representam entradas manipuladas, como vazões e aberturas de válvulas.

B. Organização dos dados

Neste estudo, os dados de operação normal foram empregados para treinamento e validação dos modelos empregados. Para a avaliação da capacidade de detecção, foram considerados dados de teste associados às falhas IDV(1), IDV(3) e IDV(5), permitindo comparar o comportamento do processo em regime normal com situações anormais de operação.

A ordem temporal adotada no experimento segue a configuração descrita por Yin et al. [3]. No estudo, os autores indicam que, considerando as constantes de tempo do processo

em malha fechada, o tempo de amostragem utilizado foi de 3 minutos. Também é dito que os conjuntos de teste possuem 48 horas de operação e que as falhas são introduzidas após 8 horas de simulação.

Assim, adotou-se:

$$T_s = 3 \text{ min.} \quad (2)$$

Como os arquivos de teste possuem 960 amostras, a duração total de cada teste é:

$$960 \cdot 3 = 2880 \text{ min} = 48 \text{ h.} \quad (3)$$

Nos arquivos de teste com falha, a falha é introduzida após 8 horas de operação. Como cada amostra representa 3 minutos, o instante de início da falha é:

$$k_f = \frac{8 \cdot 60}{3} = 160. \quad (4)$$

Sendo assim, as amostras de índice 0 a 159 representam operação normal, enquanto as amostras de índice 160 a 959 representam operação após a introdução da falha. Dessa forma, cada arquivo de falha possui:

$$960 - 160 = 800 \quad (5)$$

amostras em condição defeituosa.

C. Seleção do subconjunto

Para manter o PCA alinhado à configuração de Yin et al. [3], foi utilizado o subconjunto formado por:

$$XMEAS(1 - 22) + XMV(1 - 11), \quad (6)$$

totalizando 33 variáveis. Logo, foram selecionadas as colunas 0 a 21, correspondentes a $XMEAS(1 - 22)$, e as colunas 41 a 51, correspondentes a $XMV(1 - 11)$.

Essa escolha foi feita para seguir a configuração empregada por Yin et al. para os métodos estatísticos PCA, FDA e ICA no TEP e ainda garantir que PCA e Autoencoder recebam exatamente o mesmo conjunto de entrada, tornando a comparação mais justa.

Após essa seleção, os dados passaram a ter as dimensões:

- treino normal: 500×33 ;
- teste normal: 960×33 ;
- teste com falhas: 960×33 .

III. FALHAS ANALISADAS

Nesta implementação, foram analisadas três falhas do TEP:

- **IDV(1)**: alteração em degrau na razão de alimentação A/C;
- **IDV(3)**: alteração em degrau na temperatura da alimentação D;
- **IDV(5)**: alteração em degrau na temperatura de entrada da água de resfriamento do condensador.

A escolha dessas falhas permite observar três níveis diferentes de dificuldade. A falha IDV(1) é tratada como uma falha de fácil detecção. A falha IDV(3) possui a detecção mais difícil dentre as três falhas. A falha IDV(5) possui comportamento intermediário, com anomalia perceptível apenas no início da falha. Essa constatação é clara nos resultados apresentados por Yin et al. [3] e por Spina et al. [4].

IV. PRÉ-PROCESSAMENTO

Antes do treinamento dos modelos, os dados foram normalizados usando a média e o desvio padrão calculados exclusivamente sobre o conjunto de treinamento normal. Para cada variável x_j , foi aplicada a transformação:

$$x_j^* = \frac{x_j - \mu_j}{\sigma_j}, \quad (7)$$

Essa normalização é necessária porque as variáveis do TEP possuem escalas físicas diferentes. Sem essa etapa, variáveis de maior magnitude poderiam dominar os índices de detecção.

V. MÉTODO 1: PCA COMPLETO COM SPE E T^2

A. Ideia geral

A Análise de Componentes Principais (PCA) reduz a representação dos dados para um número menor de direções principais, preservando a maior parte da variância observada nos dados normais. Em diagnóstico de falhas, se assume que a operação normal do processo apresenta um padrão característico de correlação entre as variáveis. Quando uma nova amostra se afasta desse padrão, ela é considerada anormal.

Foram obtidos os componentes principais e a variância explicada por cada componente. Os l primeiros componentes foram então usados para formar o subespaço principal:

$$P_l = [p_1 \ p_2 \ \cdots \ p_l]. \quad (8)$$

O artigo-base apresenta, na seleção de parâmetros do estudo com o TEP, $l = 9$ componentes principais para o PCA. No presente trabalho, adotou-se o mesmo valor para manter a implementação alinhada ao artigo-base. Com as 33 variáveis selecionadas, os 9 primeiros componentes explicaram aproximadamente 67,67% da variância total dos dados normalizados.

B. Estatística SPE

A SPE (*Squared Prediction Error*), mede o erro de reconstrução da amostra pelo PCA. Ela indica o quanto uma nova amostra não consegue ser bem representada pelas componentes principais aprendidas a partir dos dados normais.

Para uma amostra x , seja $\hat{x}$ sua reconstrução no subespaço principal. O índice SPE é calculado por:

$$SPE = \|x - \hat{x}\|^2. \quad (9)$$

Assim, valores baixos de SPE indicam que a amostra segue bem a estrutura normal aprendida pelo PCA. Valores altos indicam que a reconstrução foi ruim, sugerindo um possível desvio de operação ou falha.

C. Estatística T^2

A estatística T^2 mede a distância da amostra dentro do subespaço principal. Considerando os scores t e os autovalores principais λ_i , define-se:

$$T^2 = \sum_{i=1}^l \frac{t_i^2}{\lambda_i}. \quad (10)$$

Enquanto o SPE mede erro de reconstrução fora do subespaço, o T^2 mede se a amostra está muito distante dentro do subespaço modelado.

D. Limiares de detecção

O limiar de T^2 foi calculado pela distribuição F :

$$J_{T^2} = \frac{l(N^2 - 1)}{N(N - l)} F_\alpha(l, N - l), \quad (11)$$

em que N é o número de amostras de treinamento, l é o número de componentes principais e α é o nível de confiança.

Para o SPE, foi usada a aproximação clássica de Jackson-Mudholkar. Definem-se:

$$\theta_i = \sum_{j=l+1}^m \lambda_j^i, \quad i = 1, 2, 3, \quad (12)$$

$$h_0 = 1 - \frac{2\theta_1\theta_3}{3\theta_2^2}. \quad (13)$$

Então, o limiar do SPE é dado por:

$$J_{SPE} = \theta_1 \left[\frac{c_\alpha \sqrt{2\theta_2 h_0^2}}{\theta_1} + 1 + \frac{\theta_2 h_0 (h_0 - 1)}{\theta_1^2} \right]^{1/h_0}. \quad (14)$$

No experimento, com nível de confiança de 99%, foram obtidos:

$$J_{SPE} = 23,4532, \quad (15)$$

$$J_{T^2} = 22,3948. \quad (16)$$

A regra de detecção do PCA completo foi:

$$SPE > J_{SPE} \quad \text{ou} \quad T^2 > J_{T^2} \Rightarrow \text{falha}. \quad (17)$$

Para as curvas ROC, foi usado um índice combinado normalizado:

$$s_{PCA} = \max \left(\frac{SPE}{J_{SPE}}, \frac{T^2}{J_{T^2}} \right). \quad (18)$$

Assim, a regra de detecção é equivalente a:

$$s_{PCA} > 1 \Rightarrow \text{falha}. \quad (19)$$

VI. MÉTODO 2: AUTOENCODER SIMPLES

A. Ideia geral

O Autoencoder é uma rede neural treinada para reconstruir sua própria entrada. A rede possui uma etapa de codificação, que projeta os dados para uma representação interna, e uma etapa de decodificação, que reconstrói os dados originais. Em diagnóstico de falhas, a ideia é treinar o Autoencoder apenas com dados normais. Assim, se espera que ele reconstrua as amostras normais e apresente erro maior para amostras anormais.

A codificação é dada por:

$$h = f(W_e x + b_e), \quad (20)$$

e a reconstrução por:

$$\hat{x} = W_d h + b_d. \quad (21)$$

Neste trabalho, foi implementado um Autoencoder simples subcompleto com:

- dimensão de entrada: 33;
- dimensão do código: 16;
- ativação *tanh* na camada de código;
- ativação linear na saída;

- otimizador Adam;
- função de perda MSE.

Como a dimensão do código é menor do que a dimensão da entrada, o modelo é classificado como subcompleto.

B. Erro de reconstrução

A função de perda usada no treinamento é o erro quadrático médio. Após o treinamento, o índice de detecção do Autoencoder é:

$$s_{AE}(x) = \frac{1}{m} \sum_{j=1}^m (x_j - \hat{x}_j)^2. \quad (22)$$

O limiar foi definido como o percentil 99 da distribuição do erro de reconstrução nos dados normais de teste:

$$J_{AE} = P_{99}(s_{AE}). \quad (23)$$

No experimento, o valor encontrado foi:

$$J_{AE} = 0,9702. \quad (24)$$

A regra de detecção é:

$$s_{AE}(x) > J_{AE} \Rightarrow \text{falha}. \quad (25)$$

VII. PROCEDIMENTO EXPERIMENTAL

O procedimento computacional foi organizado em seis etapas:

- 1) leitura dos dados do TEP;
- 2) validação do formato dos dados;
- 3) seleção do subconjunto;
- 4) normalização das variáveis com média e desvio padrão calculados apenas sobre o treino normal;
- 5) treinamento do PCA e do Autoencoder simples usando somente os dados normais;
- 6) avaliação das falhas IDV(1), IDV(3) e IDV(5) usando FAR, FDR, curvas ROC e AUC.

Essa organização surge da ideia de diagnóstico baseado em dados: os modelos aprendem a condição normal do processo e, depois, são avaliados a capacidade de identificar falhas em dados de teste.

VIII. MÉTRICAS DE AVALIAÇÃO

Foram utilizadas três métricas principais: FAR, FDR e AUC.

A taxa de falso alarme, FAR, mede a fração de amostras normais classificadas como falha:

$$FAR = \frac{\#\{s > J \mid f = 0\}}{\#\{f = 0\}} \cdot 100\%. \quad (26)$$

A taxa de detecção de falhas, FDR, mede a fração de amostras com falha classificadas corretamente como falha:

$$FDR = \frac{\#\{s > J \mid f \neq 0\}}{\#\{f \neq 0\}} \cdot 100\%. \quad (27)$$

Para cada arquivo de falha, a região normal foi composta pelo arquivo com dados normais e pelas primeiras 160 amostras do próprio arquivo de falha. Essa definição vem da configuração temporal de Yin et al. [3], na qual a falha é introduzida apenas após 8 horas de operação. A região

defeituosa foi composta pelas amostras posteriores ao início da falha, isto é, as amostras $k \geq 160$.

Além de FAR e FDR no limiar fixo, foram calculadas curvas ROC e a métrica AUC. Essa ideia permite comparar os métodos independentemente de um único limiar fixo, metodologia que advém do estudo de Spina et al. [4].

IX. RESULTADOS

A. Resultados quantitativos

A Tabela I resume os resultados obtidos para as três falhas avaliadas.

B. Índices de detecção no tempo

A Figura 1 apresenta os índices de detecção ao longo do tempo para os dois métodos e para as três falhas. A linha horizontal indica o limiar de detecção e a linha vertical indica o instante de início da falha.

Para a falha IDV(1), percebe-se que ambos os métodos ultrapassam o limiar logo após o início da falha. Esse comportamento confirma que IDV(1) é uma falha fácil de detecção. O índice permanece acima do limiar durante todo o restante da simulação.

Para a falha IDV(3), os índices permanecem próximos do limiar e apresentam baixa diferença entre as regiões normal e defeituosa. Isso explica os baixos valores de FDR e AUC obtidos para os dois métodos.

Para a falha IDV(5), os dois métodos detectam um transiente forte após o início da falha. Porém, após algumas horas, o índice tende a retornar para valores próximos ou abaixo do limiar.

C. Curvas ROC

A Figura 2 apresenta as curvas ROC obtidas para as falhas IDV(1), IDV(3) e IDV(5).

Na falha IDV(1), as curvas dos dois métodos ficam próximas do canto superior esquerdo, com AUC praticamente igual a 1. Isso indica excelente capacidade de separar as amostras normais e com falha.

Na falha IDV(3), as curvas ficam próximas da diagonal. O PCA obteve AUC de 0,5848 e o Autoencoder obteve AUC de 0,5774. Isso indica que ambos os métodos possuem baixa capacidade de separação para essa falha.

Na falha IDV(5), o Autoencoder apresentou AUC de 0,7749, superior ao valor de 0,7038 obtido pelo PCA. Isso indica que, considerando diferentes limiares, o Autoencoder separou melhor as regiões normal e defeituosa. No limiar fixo utilizado, entretanto, o PCA apresentou FDR maior, com 33,625% contra 25,625% do Autoencoder.

D. Comparação com os resultados da literatura

A Tabela II compara os resultados obtidos neste trabalho com valores reportados nos artigos utilizados como referência. Essa comparação precisa ser interpretada de acordo com o método avaliado. Para o PCA, a comparação com Yin et al. [3] é direta, pois toda metodologia segue a configuração do artigo-base. Para o Autoencoder, a comparação com Spina et

al. [4] é uma comparação diferente, pois este trabalho usa um subconjunto, enquanto o artigo considera o conjunto completo de variáveis.

No caso do PCA, os resultados obtidos ficaram praticamente iguais aos reportados por Yin et al. [3]. Para IDV(1), o artigo reporta FDR de 99.88%, enquanto este trabalho obteve 99.875%. Para IDV(3), o valor reportado é 12.88%, e o valor obtido foi 12.875%. Para IDV(5), o artigo reporta 33.63%, enquanto o resultado obtido foi 33.625%. Essa proximidade indica que a implementação do PCA completo está coerente com a formulação do artigo-base.

No caso do Autoencoder simples, os resultados também preservaram os resultados obtidos por Spina et al. [4]. A falha IDV(1) apresentou FDR próximo de 100%, a falha IDV(3) teve baixa taxa de detecção e a falha IDV(5) apresentou dificuldade intermediária. A diferença mais evidente ocorreu em IDV(5), em que o AE undercomplete de Spina et al. reporta FDR de 36.25%, enquanto este trabalho obteve 25.625%. Essa diferença é plausível.

X. DISCUSSÃO

Os resultados mostram que a dificuldade de detecção depende fortemente da falha analisada. Esse comportamento está de acordo com os artigos utilizados como referência. A falha IDV(1) foi facilmente detectada por ambos os métodos, apresentando FDR próximo de 100% e AUC praticamente unitária. Esse resultado confirma que essa falha gera uma alteração evidente no comportamento das variáveis.

A falha IDV(3), por outro lado, apresentou baixa taxa de detecção para os dois métodos. Esse comportamento também é coerente com a literatura, pois essa falha é reconhecida como uma das mais difíceis de detectar no TEP. Os valores obtidos de métricas indicam baixa diferença entre as regiões normal e defeituosa.

A falha IDV(5) apresentou comportamento intermediário. O PCA obteve FDR de 33.625% e AUC de 0.7038, enquanto o Autoencoder obteve FDR de 25.625% e AUC de 0.7749. Portanto, no limiar fixo adotado, o PCA detectou uma parcela maior das amostras com falha. Ao considerar a curva ROC e diferentes limiares na análise, o Autoencoder apresentou melhor separabilidade global para essa falha.

O PCA completo apresentou a vantagem de usar dois índices complementares. A combinação entre SPE e T^2 combinação tornou o método mais sensível, principalmente em relação ao uso isolado do erro de reconstrução. Por outro lado, o uso simultâneo de dois critérios também aumentou a taxa de falso alarme, que ficou em torno de 5%. Esse comportamento é esperado, pois a regra de decisão considera falha quando qualquer um dos dois índices ultrapassa seu respectivo limiar.

O Autoencoder simples apresentou menor FAR no limiar adotado, aproximadamente 0.8929%. Isso ocorre porque seu limiar foi definido pelo percentil 99 do erro de reconstrução em dados normais. A ideia central do método está alinhada ao estudo de Spina et al. [4]: treinar a rede apenas com dados normais e usar o erro de reconstrução como índice de anomalia. Assim, amostras que não são bem reconstruídas tendem a ser classificadas como falha.

Tabela I
RESULTADOS OBTIDOS PARA PCA COMPLETO E AUTOENCODER SIMPLES NAS FALHAS IDV(1), IDV(3) E IDV(5).

Falha	Método	FAR (%)	FDR (%)	AUC
IDV(1)	PCA (SPE+ T^2)	5.3571	99.875	0.9998
	Autoencoder	0.8929	99.750	0.9999
IDV(3)	PCA (SPE+ T^2)	5.2679	12.875	0.5848
	Autoencoder	0.8929	2.250	0.5774
IDV(5)	PCA (SPE+ T^2)	5.4464	33.625	0.7038
	Autoencoder	0.8929	25.625	0.7749

Tabela II
COMPARAÇÃO ENTRE OS RESULTADOS OBTIDOS NESTE TRABALHO E VALORES REPORTADOS NA LITERATURA PARA AS FALHAS IDV(1), IDV(3) E IDV(5).

Referência	Método	FAR (%)	FDR IDV(1) (%)	FDR IDV(3) (%)	FDR IDV(5) (%)
Yin et al. [3]	PCA	6.13	99.88	12.88	33.63
Este trabalho	PCA	5.36–5.45	99.875	12.875	33.625
Spina et al. [4]	AE undercomplete	1.00	99.75	1.63	36.25
Este trabalho	AE undercomplete	0.8929	99.750	2.250	25.625




Figura 1. Índices de detecção no tempo para PCA completo e Autoencoder simples nas falhas IDV(1), IDV(3) e IDV(5).




Figura 2. Curvas ROC para comparação entre PCA completo e Autoencoder simples.

A comparação com Yin et al. [3] reforça a consistência da implementação do PCA. Os valores de FDR obtidos para IDV(1), IDV(3) e IDV(5) foram praticamente iguais aos valores reportados no artigo. Essa proximidade sugere que o car-

regamento dos dados, a seleção das variáveis, a normalização, os limiares e os índices SPE e T^2 foram implementados de maneira análoga ao artigo-base.

Spina et al. [4], por sua vez, avalia diferentes arquiteturas, incluindo Deep AE, Denoising AE, Deep DAE e VAE, além de versões sparse e undercomplete. O presente trabalho implementa apenas um Autoencoder simples subcompleto. Além disso, o estudo de Spina et al. considera o conjunto completo de 52 variáveis, enquanto este trabalho, apenas 33. Mesmo assim, a tendência geral foi preservada.

XI. CONCLUSÕES

Este trabalho implementou um pipeline para diagnóstico de falhas baseado em dados no Tennessee Eastman Process. Os dados foram carregados diretamente do pacote local, e o subconjunto com 33 variáveis foi utilizado para manter o PCA alinhado à configuração de Yin et al. e garantir entrada comum para os dois modelos avaliados.

Foram comparados dois métodos: PCA completo com SPE e T^2 , alinhado à formulação usada por Yin et al. [3], e Autoencoder simples subcompleto, baseado na estratégia de reconstrução de dados normais discutida por Spina et al. [4]. Foram adotadas definições de tempo de amostragem de 3 minutos, teste de 48 horas e introdução da falha após 8 horas, se utilizando de 9 componentes principais do PCA.

Os principais resultados foram:

- 1) A falha IDV(1) foi detectada com alta eficiência pelos dois métodos, com AUC próxima de 1;
- 2) A falha IDV(3) foi difícil para ambos os modelos, com AUC próxima de 0,58;
- 3) A falha IDV(5) apresentou comportamento intermediário, com melhor AUC para o Autoencoder e maior FDR no limiar fixo para o PCA;
- 4) O PCA reproduziu os mesmos FDRs reportados pelo artigo-base para as três falhas analisadas;
- 5) O Autoencoder apresentou comportamento coerente com a lógica do artigo-base.

Assim, os resultados confirmam que ambas as técnicas são úteis para diagnóstico de falhas, mesmo com comportamentos e metodologias distintas. O PCA é mais interpretável e segue uma formulação estatística bem definida. O Autoencoder oferece uma alternativa baseada em aprendizado de máquina, com potencial de expansão para arquiteturas mais complexas e mais inteligentes.

REFERÊNCIAS

- [1] J. J. Downs and E. F. Vogel, "A plant-wide industrial process control problem," *Computers & Chemical Engineering*, vol. 17, no. 3, pp. 245–255, 1993.
- [2] L. H. Chiang, E. L. Russell, and R. D. Braatz, *Fault Detection and Diagnosis in Industrial Systems*. London: Springer-Verlag, 2001.
- [3] S. Yin, S. X. Ding, A. Haghani, H. Hao, and P. Zhang, "A comparison study of basic data-driven fault diagnosis and process monitoring methods on the benchmark Tennessee Eastman process," *Journal of Process Control*, vol. 22, no. 9, pp. 1567–1581, 2012.
- [4] D. E. Spina, L. F. de O. Campos, W. F. de Arruda, A. Melo, M. F. de S. Alves, G. L. Rabello, T. K. Anzai, and J. C. Pinto, "Comparison of autoencoder architectures for fault detection in industrial processes," *Digital Chemical Engineering*, vol. 12, 100162, 2024.

- [5] R. D. Braatz Research Group, "Open-loop and closed-loop simulations for the Tennessee Eastman process," University of Illinois / MIT Braatz Group. [Online]. Available: http://web.mit.edu/braatzgroup/TE_process.zip