

Sintonia de Covariâncias em Kalman: validação linear e aplicação no problema de posicionamento

José Tayrone Santos de Oliveira

Resumo—Este trabalho estuda a sintonia de covariâncias de ruído em filtros de Kalman a partir de dois casos complementares. No primeiro caso, implementa-se e valida-se, em um problema linear do artigo-base de Zhang et al., uma estratégia de estimação do ganho estacionário a partir das autocovariâncias da inovação, seguida da estimação de R , Q e P , com verificação por NIS e NEES. No segundo caso, considera-se um problema de posicionamento baseado em medições de distância até estações-base fixas, cuja observação é não linear. Como o método de Zhang foi formulado para sistemas lineares estacionários, a aplicação do método ao problema de posicionamento é feita linearizando localmente o modelo de observação em torno de um ponto de operação e aplicando a lógica do caso linear nesse modelo local. Os resultados mostram que, no caso linear, a implementação recupera adequadamente o ganho ótimo e as covariâncias, produzindo resultados consistentes. No caso de posicionamento, a identificação local de W e R mostrou-se coerente, mas a etapa final de estimação de Q , P e a validação por NEES ainda apresentaram limitações. Assim, o estudo valida o método para problemas lineares e mostra um desempenho local parcial ao problema de posicionamento.

Index Terms—Sintonia, Filtro de Kalman, filtro de Kalman estendido, identificação de covariâncias, inovação, NIS, NEES, posicionamento local, linearização local.

I. INTRODUÇÃO

O filtro de Kalman é uma ferramenta para estimação de estados em sistemas sujeitos a componentes de ruído. Seu uso é variado em sistemas de navegação, rastreamento e controle. Entretanto, seu desempenho depende diretamente da escolha adequada das covariâncias de ruído do processo e da medição. Quando essas matrizes são mal ajustadas ou mal escolhidas, o filtro pode se tornar confiante demais, excessivamente conservador ou simplesmente gerar estimativas ruins [1], [2], [6].

Este estudo foi estruturado por dois artigos. O primeiro é o trabalho de Zhang et al. [1], cujo foco é o problema de identificar covariâncias de ruído desconhecidas em filtros de Kalman lineares. O segundo é o artigo de Falek e Kaniowski [4], que apresenta uma aplicação computacional para testar um filtro de Kalman estendido em um sistema de posicionamento baseado em medições de distância até estações-base. Nesse segundo caso, a dinâmica é linear, mas a observação é não linear, o que exige o uso do EKF.

A dificuldade central do estudo é que o método de Zhang foi desenvolvido para o caso linear, enquanto o problema de posicionamento trabalha com observações não lineares. Por esse motivo, o trabalho foi dividido em dois casos.




Figura 1. Representação conceitual do problema de posicionamento local por distâncias até estações-base fixas.

Primeiro, implementou-se o método no domínio em que a teoria lhe é favorável, isto é, em um problema linear do próprio artigo-base. Depois, utilizou-se uma estratégia conservadora para replicar esse método ao problema de posicionamento: construiu-se um modelo linear local por meio da linearização da observação em torno de um ponto de operação específico. Essa opção permite a aplicação da lógica do artigo-base no problema em que se exige EKF. Assim, neste trabalho, o problema de posicionamento não é tratado por uma sintonia global do EKF completo, mas por uma extensão local da lógica de Zhang ao modelo linearizado em torno de um ponto de operação.

A Figura 1 ilustra o problema físico de posicionamento por distâncias. Já a Figura 2 mostra a geometria específica adotada nas simulações deste trabalho. Nela aparecem as quatro estações-base e a trajetória do objeto móvel no plano. Essa visualização mostra que a observação por distâncias é naturalmente não linear.

II. OBJETIVOS E ORGANIZAÇÃO DO TRABALHO

O objetivo principal deste trabalho é analisar como a lógica de identificação de covariâncias baseada na inovação pode ser implementada em dois casos:

- 1) **Validação linear:** implementar o método em um caso linear do artigo-base e verificar se o ganho estacionário, as covariâncias e os testes de consistência se comportam como relatado pelos autores;




Figura 2. Geometria global do problema estudado: estações-base fixas e trajetória nominal do objeto no plano.

2) **Problema de posicionamento:** construir um modelo linear local a partir da observação não linear das distâncias e aplicar nesse modelo a lógica validada no caso linear.

Mais especificamente, o trabalho buscou:

- revisar a formulação matemática do filtro de Kalman e os diagnósticos de consistência;
- explicar a ideia do método de Zhang;
- validar numericamente a implementação no *Case 2* do artigo-base;
- formular um segundo caso baseado no sistema de posicionamento local com medições de distância, usando uma linearização local da observação;

O texto foi organizado da seguinte forma. A Seção III apresenta a formulação do problema e os diagnósticos. A Seção IV resume o método do artigo-base. A Seção V descreve o sistema de posicionamento. A Seção VI apresenta a metodologia dos dois casos estudados. A Seção VII discute os resultados. Por fim, as Seções VIII e IX trazem a discussão e as conclusões.

III. FORMULAÇÃO DO PROBLEMA E DIAGNÓSTICOS DE CONSISTÊNCIA

A. Modelo linear discreto

Considere o sistema linear discreto

$$x_{k+1} = Fx_k + Gw_k, \quad (1)$$

$$z_k = Hx_k + v_k, \quad (2)$$

em que:

- x_k é o vetor de estados;
- z_k é o vetor de medições;
- F é a matriz de transição de estados;
- G é a matriz de entrada do ruído de processo;
- H é a matriz de medição;
- $w_k \sim \mathcal{N}(0, Q)$ é o ruído de processo;
- $v_k \sim \mathcal{N}(0, R)$ é o ruído de medição.

No filtro de Kalman clássico, a etapa de predição é dada por

$$\hat{x}_{k|k-1} = F\hat{x}_{k-1|k-1}, \quad (3)$$

$$P_{k|k-1} = FP_{k-1|k-1}F^\top + GQG^\top, \quad (4)$$

e a etapa de atualização é

$$\nu_k = z_k - H\hat{x}_{k|k-1}, \quad (5)$$

$$S_k = HP_{k|k-1}H^\top + R, \quad (6)$$

$$K_k = P_{k|k-1}H^\top S_k^{-1}, \quad (7)$$

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k\nu_k. \quad (8)$$

A variável ν_k é a *inovação*. Ela mede a diferença entre a medição recebida e a medição prevista pelo filtro. Quando o filtro está corretamente ajustado, a inovação deve ter média próxima de zero, covariância compatível com S_k e pouca correlação temporal [5], [6].

B. Matrizes: Q , R , K , W e P

Tem-se:

- Q : covariância do ruído de processo. Representa quanto o modelo dinâmico pode errar;
- R : covariância do ruído de medição. Representa o nível de incerteza;
- K_k : ganho de Kalman em cada instante. É o balanço entre confiar na predição e confiar na medição;
- $P_{k|k}$ e $P_{k|k-1}$: covariâncias de erro do estado atualizado e predito;
- W : ganho de Kalman estacionário. No artigo de Zhang, ele é tratado como o objetivo central a ser identificado antes de recuperar R , Q e P [1].

Em termos simples, se R for muito pequeno, o filtro tende a confiar demais nas medições; se Q for muito pequeno, o filtro tende a confiar demais no modelo. A boa sintonia depende do equilíbrio entre essas duas matrizes [5].

C. Diagnósticos baseados em inovação

Os dois diagnósticos usados para avaliar se Q e R estão bem ajustados são o NIS e o NEES [6].

O NIS é

$$\epsilon_{z,k} = \nu_k^\top S_k^{-1} \nu_k. \quad (9)$$

Idealmente, $\epsilon_{z,k}$ segue distribuição qui-quadrado com m graus de liberdade, em que m é a dimensão da medição. Em particular,

$$\mathbb{E}[\epsilon_{z,k}] = m. \quad (10)$$

Quando o estado verdadeiro está disponível, pode-se usar também o NEES:

$$\epsilon_{x,k} = \tilde{x}_{k|k}^\top P_{k|k}^{-1} \tilde{x}_{k|k}, \quad (11)$$

onde $\tilde{x}_{k|k} = x_k - \hat{x}_{k|k}$. Com,

$$\mathbb{E}[\epsilon_{x,k}] = n, \quad (12)$$

em que n é a dimensão do estado [6].

Além disso, também é útil analisar a inovação branqueada

$$e_k = S_k^{-1/2} \nu_k, \quad (13)$$

pois, para um filtro bem ajustado, ela deve ter aproximadamente de média zero, covariância próxima da identidade e pouca autocorrelação fora do lag zero [6].

IV. MÉTODO DE IDENTIFICAÇÃO DE COVARIÂNCIAS DO ARTIGO-BASE

A. Ideia principal

A estratégia do artigo é não começar estimando Q e R diretamente. Em vez disso, primeiro busca-se um ganho estacionário W que torne a inovação o mais branca possível. Uma vez conhecido um bom W , se torna possível calcular R , Q , $\hat{P}$ e P [1].

O artigo define uma função objetivo baseada nas autocovariâncias amostrais da inovação,

$$\hat{C}(i) = \frac{1}{N-M} \sum_{j=1}^{N-M} \nu(j) \nu^\top(j+i), \quad i = 0, 1, \dots, M-1, \quad (14)$$

e procura um ganho W que faça $\hat{C}(i)$ tender a zero para $i > 0$ [1], [2].

B. Uso dos post-fit residuals

Uma vez encontrado o ganho ótimo W , Zhang et al. exploram sequências de *post-fit residuals*

$$\mu(k) = z(k) - H\hat{x}(k|k) \quad (15)$$

para estimar R . Em seguida, Q e P são estimados iterativamente.

V. PROBLEMA DE POSICIONAMENTO COM OBSERVAÇÃO NÃO LINEAR

A. Sistema considerado

O segundo problema estudado considera um sistema de posicionamento de um objeto móvel baseado em medições de distância até estações-base fixas [4]. O objeto move-se em um plano horizontal OXY , e as medições são atualizadas a cada 1 s.

As distâncias medidas até as estações são dadas por

$$d_i = \sqrt{(X_i - x)^2 + (Y_i - y)^2} + v_i, \quad (16)$$

em que (X_i, Y_i) são as coordenadas da estação i , (x, y) são as coordenadas do objeto e v_i é o erro da medição [4].

Com quatro estações-base, a medição pode ser escrita como

$$z(k) = [d_1 \ d_2 \ d_3 \ d_4]^\top. \quad (17)$$

O artigo destaca que a observação é não linear, e, por isso, recorre ao filtro de Kalman estendido, usando a matriz de observação obtida como jacobiano da função $h(x)$ [4].

B. Modelo PV

Para esse trabalho, optou-se por trabalhar com o modelo PV em duas dimensões, com vetor de estados

$$x_k = [p_x \ v_x \ p_y \ v_y]^\top, \quad (18)$$

pois essa escolha simplifica a passagem do caso linear ao problema aplicado.

C. Por que o método do artigo-base não pode ser aplicado diretamente?

O método de Zhang foi formulado para sistemas lineares com ganho estacionário W . Porém, no problema de posicionamento, a matriz de observação depende do estado atual via jacobiano. Assim, o ganho do EKF varia com o tempo. Portanto, aplicar o método de Zhang literalmente ao problema completo exigiria métodos que não foram desenvolvidos e exibidos no artigo-base [1], [4].

Para evitar esse passo teórico extra, adotou-se uma solução a parte: linearizar localmente a observação em torno de um ponto de operação e aplicar a lógica do caso linear nesse modelo local.

VI. METODOLOGIA DOS DOIS CASOS

A. Caso 1: validação da implementação no Case 2 do artigo-base

O primeiro caso foi construído diretamente a partir do *Case 2* apresentado por Zhang et al. [1]. Nesse exemplo, o sistema linear discreto é dado por

$$x(k) = \begin{bmatrix} 0.8 & 1 \\ -0.4 & 0 \end{bmatrix} x(k-1) + \begin{bmatrix} 1 \\ 0.5 \end{bmatrix} v(k-1), \quad (19)$$

$$z(k) = \begin{bmatrix} 1 & 0 \end{bmatrix} x(k) + w(k), \quad (20)$$

com $q_{\text{true}} = 1$, $r_{\text{true}} = 1$ e ganho inicial subótimo

$$W^{(0)} = \begin{bmatrix} 0.9 \\ 0.5 \end{bmatrix}. \quad (21)$$

Neste caso, adotou-se uma configuração aproximada da apresentada no artigo-base, com $M = 100$ lags na função objetivo e 100 rodadas Monte Carlo com 1000 amostras por rodada. O objetivo foi verificar se a implementação reproduzia o comportamento esperado para o *Case 2*, antes de avançar para o problema de posicionamento.

A implementação foi organizada em quatro passos:

- 1) geração da trajetória verdadeira e das medições;
- 2) busca do ganho estacionário W por minimização da autocorrelação residual da inovação;
- 3) estimação de R a partir dos *post-fit residuals*;
- 4) estimação iterativa de q e de P , seguida de diagnósticos por NIS, NEES e Monte Carlo.

Nessa etapa, o objetivo foi verificar se a implementação reproduzia o comportamento esperado apresentado pelo artigo-base.

B. Caso 2: extensão local ao problema de posicionamento

No segundo caso, partiu-se da geometria do sistema de posicionamento com quatro estações-base posicionadas nos cantos de uma área quadrada e uma trajetória quadrada no plano. Como o modelo PV é linear e a observação por distâncias é não linear, foi escolhida uma janela local em um trecho reto da trajetória e calculado um ponto de operação

$$x^* = [300 \ 5.0633 \ 100 \ 0]^\top. \quad (22)$$

A partir desse ponto, calculou-se o jacobiano fixo H^* do modelo de observação. Como visto na Figura 3, essa etapa

não foi feita em qualquer ponto da trajetória, mas em um trecho reto, afastado dos cantos, para reduzir o efeito de incompatibilidade entre a trajetória quadrada e o modelo PV. A figura também mostra o jacobiano local H^* , que passa a desempenhar o papel da matriz de observação do modelo linearizado.

Em torno desse ponto, a função de observação foi aproximada por

$$h(x) \approx h(x^*) + H^*(x - x^*). \quad (23)$$

Definindo

$$\delta x_k = x_k - x^*, \quad \delta z_k = z_k - h(x^*), \quad (24)$$

obteve-se o modelo linear local

$$\delta x_{k+1} = F\delta x_k + w_k, \quad (25)$$

$$\delta z_k \approx H^*\delta x_k + v_k. \quad (26)$$

Aplicou-se a mesma lógica do caso linear: ajuste de um ganho fixo W a partir da inovação, estimação de R via *post-fit residuals* e estimação iterativa de S_a , Q e P no próprio modelo linear local. Assim, a leitura correta do caso 2 é a de uma sintonia local, e não a de uma solução final.

VII. RESULTADOS

A. Resultados do caso linear e validação contra o Case 2

No primeiro caso, implementou-se o método no mesmo sistema do *Case 2* do artigo-base. A partir do ganho inicial subótimo

$$W_0 = \begin{bmatrix} 0.9 \\ 0.5 \end{bmatrix},$$

a otimização produziu

$$W_{\text{est}} = \begin{bmatrix} 0.646170 \\ 0.107271 \end{bmatrix}, \quad W_{\text{true}} = \begin{bmatrix} 0.654230 \\ 0.088286 \end{bmatrix},$$

com redução da função objetivo de $J = 0.220084$ para $J = 0.004460$. Como visto na Figura 4, a queda da função objetivo foi rápida e os elementos de W convergiram para valores próximos dos de referência.

A estimação das covariâncias produziu

$$R_{\text{est}} = 1.001308, \quad q_{\text{est}} = 0.985057, \quad (27)$$

frente a valores verdadeiros iguais a 1.0 para ambos. Esses resultados são compatíveis com o comportamento reportado por Zhang et al. para o *Case 2*: as estimativas de W , R e Q permanecem próximas dos valores verdadeiros. Em particular, os valores estimados de W_1 , W_2 , R e q ficaram na mesma faixa dos valores médios reportados por Zhang et al. para o *Case 2*, o que reforça e valida a implementação desse trabalho.

Além disso, os diagnósticos estatísticos confirmaram a consistência do filtro identificado. A média da NIS foi igual a 1.0, a média da NEES foi 2.056431, a média da inovação branqueada ficou próxima de zero e sua variância ficou praticamente unitária. Como ilustrado na Figura 5, a inovação branqueada apresentou autocorrelação muito pequena para lags não nulos e histograma aproximadamente simétrico em torno de zero.

Em Monte Carlo com 100 rodadas de 1000 amostras, obteve-se

$$\overline{\text{NIS}}_{\text{MC}} = 1.018042, \quad \overline{\text{NEES}}_{\text{MC}} = 2.008096, \quad (28)$$

ambos muito próximos dos valores esperados. Como mostrado na Figura 6, tanto a ANIS quanto a ANEES convergiram para os valores de referência, reforçando que a implementação não apenas recuperou bem os parâmetros, mas também produziu um filtro consistente.

Portanto, o caso 1 cumpre o papel de validação da implementação do *Case 2* do artigo-base: o ganho identificado ficou próximo do ganho de referência, as covariâncias estimadas ficaram próximas das verdadeiras e os testes de consistência atestaram a qualidade do filtro.

B. Resultados do caso de posicionamento

No segundo caso, a função objetivo baseada nas autocovariâncias da inovação começou em

$$J(W_0) = 5.941590 \quad (29)$$

e foi reduzida para

$$J(W) = 0.015897, \quad (30)$$

com erro Frobenius entre o ganho identificado e o ganho teórico local igual a

$$\|W_{\text{est}} - W_{\text{true,local}}\|_F = 0.040016. \quad (31)$$

Esses números mostram que a identificação local de W foi bem-sucedida no modelo linearizado.

A estimação de R local produziu

$$\|R_{\text{est}} - R_{\text{true}}\|_F = 0.111618, \quad (32)$$

valor que pode ser considerado razoável para o modelo local adotado. Além disso, a média da NIS local foi

$$\overline{\text{NIS}} = 4.0, \quad (33)$$

exatamente igual ao valor esperado para uma medição de dimensão 4.

Esses resultados atestam que a identificação local de W e R foi coerente no modelo linearizado. Em outras palavras, a parte do método ligada à inovação e aos *post-fit residuals* teve desempenho satisfatório também neste caso.

Porém, a etapa final de estimação de S_a , Q e P não mostrou o mesmo comportamento. Obteve-se

$$S_{a,\text{est}} = 0.285680, \quad S_{a,\text{true}} = 0.1, \quad (34)$$

e

$$\|Q_{\text{est}} - Q_{\text{true}}\|_F = 0.333306. \quad (35)$$

A média da NEES local ficou em

$$\overline{\text{NEES}} = 2.995980 \times 10^6, \quad (36)$$

quando o valor esperado seria 4.

A Figura 7 resume o comportamento crítico do segundo caso. Nela, observa-se que a ANIS local se estabiliza em torno de 4, enquanto a ANEES explode. Isso mostra que a parte




Figura 3. Trecho local escolhido para linearização, ponto de operação x^* e representação do jacobiano H^* .




Figura 4. Redução da função objetivo e evolução dos elementos do ganho estacionário no caso linear.




Figura 5. Autocorrelação da inovação branqueada e histograma correspondente no caso linear. Observa-se baixa correlação para lags não nulos e distribuição aproximadamente centrada em zero, coerentes com a hipótese de inovação branca.

ligada à inovação e à estimação de R ficou coerente, mas a etapa de Q , P e S_a não se saiu tão bem numericamente.

Portanto, no caso 2, o resultado deve ser interpretado como uma extensão local e parcial: a identificação local de W e R foi bem-sucedida, mas a etapa final de Q , P e NEES apresentou algumas limitações.

C. Síntese comparativa

Os dois casos desempenham papéis complementares. O primeiro responde se a implementação do método está correta no domínio linear do artigo-base. O segundo responde como essa lógica pode ser levada ao problema de posicionamento mesmo que de forma limitada. Em resumo:

- o caso 1 fornece **validação metodológica**;
- o caso 2 fornece **uma extensão local e parcial ao**




Figura 6. Diagnósticos de consistência do caso linear por meio de ANIS e ANEES em Monte Carlo.




Figura 7. ANIS e ANEES no modelo linear local do caso 2. A NIS permanece coerente, mas a NEES cresce muito acima do valor esperado.

problema aplicado.

VIII. DISCUSSÃO

A principal lição do caso linear é que a lógica baseada na inovação, nos *post-fit residuals* e nos testes NIS/NEES funciona bem quando o problema satisfaz as hipóteses do método. Isso não é trivial, pois a literatura mostra que identificar Q e R é um problema antigo e delicado, com várias dificuldades [1]–[3].

Já no problema de posicionamento, a escolha de linearizar localmente tem vantagens e limitações. A vantagem é conceitual: ela respeita o fato de que o artigo de Zhang foi formulado para sistemas lineares e que o EKF trabalha precisamente com linearizações locais [1], [4]. A limitação é prática: mesmo dentro do modelo local, a etapa de Q , P e NEES mostrou-se frágil e limitada. Portanto, a extensão ao caso 2 não pode ser apresentada como uma solução completa do problema de posicionamento, mas como uma decisão controlada.

IX. CONCLUSÕES

Esse relatório estudou a identificação de covariâncias de ruído em filtros de Kalman a partir de dois casos. No primeiro, implementou-se o método de Zhang et al. em um problema linear do próprio artigo-base e verificou-se que a identificação do ganho estacionário, da covariância de medição e do ruído de

processo produz resultados próximos dos valores de referência, com diagnósticos consistentes de inovação, NIS e NEES. Esse caso forneceu a validação da implementação computacional do problema.

No segundo caso, utilizou-se um sistema de posicionamento com medições de distância até quatro estações-base fixas. Como a observação nesse problema é não linear, não se aplicou o método de Zhang diretamente ao EKF completo. Em vez disso, adotou-se uma estratégia a parte: linearizou-se localmente a observação em torno de um ponto de operação e aplicou-se a lógica do caso linear a esse modelo local. Nessa extensão, a identificação local de W e R foi coerente, mas a etapa final de Q , P e a validação por NEES apresentaram limitações numéricas.

Assim, através desse trabalho mostrou-se que:

- 1) a implementação linear do método está de acordo com o esperado;
- 2) é possível transportar sua lógica para um modelo linear local obtido a partir do problema de posicionamento;
- 3) essa extensão local funciona apenas de forma parcial, sendo adequada como estudo complementar, mas não como solução final do problema não linear completo.

REFERÊNCIAS

- [1] L. Zhang, D. Sidoti, A. Bienkowski, K. R. Pattipati, Y. Bar-Shalom e D. L. Kleinman, “On the Identification of Noise Covariances and Adaptive

- Kalman Filtering: A New Look at a 50 Year-Old Problem,” *IEEE Access*, vol. 8, pp. 59362–59388, 2020.
- [2] R. K. Mehra, “On the Identification of Variances and Adaptive Kalman Filtering,” *IEEE Transactions on Automatic Control*, vol. AC-15, no. 2, pp. 175–184, 1970.
 - [3] B. Carew e P. R. Bélanger, “Identification of Optimum Filter Steady-State Gain for Systems with Unknown Noise Covariances,” *IEEE Transactions on Automatic Control*, vol. AC-18, no. 6, pp. 582–587, 1973.
 - [4] P. Falek e P. Kaniewski, “Computer application for testing Kalman filter,” in *Proc. SPIE 11442, Radioelectronic Systems Conference 2019*, 2020.
 - [5] A. M. N. Lima, “Properties of the Discrete-Time Kalman Filter,” notas de aula, UFCG, 2026.
 - [6] A. M. N. Lima, “Testing whether Q and R are properly set,” notas de aula, UFCG, 2026.